

Inteligência Computacional: Exploração dos Métodos

Guilherme Campos Silva Lemes Prestes - 13720460 ¹

Armando Augusto Marchini Vidal - 13673072 ¹

¹Escola de Artes, Ciências e Humanidades da Universidade de São Paulo

Junho 2025

CNN e Classificações Horizontais

- CNN possuem camadas sequenciais de convolução e uma camada de saída
 - Abstrai os dados de entrada para aprender com base na estrutura hierárquica;
 - Trata todas as categorias como igualmente complexas e exclusivas;
- Aplicação inversa da ideia
 - Predição em uma classificação hierárquica usando várias camadas de saída com abstrações de classe cada vez maiores.

Classificação Hierárquica

- Representação em árvore com relação “é-um” (“is-a”)
 - $\exists! R \in C : \forall c \in C, c \neq R \Rightarrow c \prec R$
 - $\forall c_i, c_j \in C, c_i \prec c_j \Rightarrow c_j \not\prec c_i$
 - $\forall c_i \in C, c_i \not\prec c_i$
 - $\forall c_i, c_j, c_k \in C, (c_i \prec c_j \wedge c_j \prec c_k) \Rightarrow c_i \prec c_k$
 - Assimetria, Transitividade e Antirreflexiva
 - Exemplo: Um “gato” um “pet” que é um “animal”
- Distinção entre conceitos mais amplos e simples de características específicas para subcategorias.

Branch Convolutional Neural Networks (B-CNNs)

- Uso da CNN como “espinha dorsal” para extrair as características’
 - Outros algoritmos (HD-CNN) já usavam a técnica;
- Redes neurais como ramificações para os diferentes níveis de hierarquia
 - As ramificações recebem as características do bloco inicial;
 - Feedforward que predita um único nível da hierarquia;
 - Soma ponderada da função de perda de cada ramificação para gerar função de perda de treino.

Branch Convolutional Neural Networks (B-CNNs)




Figura: Arquitetura da BCNN

CNN e a Hierarquia Inerente

- Uma CNN já possui características hierárquicas
 - Camadas mais baixas capturam informações mais gerais
 - Camadas mais altas capturam características complexas
- B-CNN se encaixa a partir dessa arquitetura
 - Ramificações são inseridas em diferentes pontos da classificação da CNN
 - Conhecimento prévio da hierarquia das classes

- Método que contorna a forma estática e "top-down" do B-CNN
 - Propagação unilateral traz perda de informação descoberta em níveis mais profundos
 - Conectividade não muda durante treino
- Conexão das ramificações por mecanismo de atenção
 - Predições condicionadas a vetores de contexto de toda a hierarquia
 - Os vetores mantêm características de diversos níveis da hierarquia
- O módulo de atenção fica entre as representações de características das ramificações e a camada de saída

BA-CNN




Figura: Arquitetura BA-CNN

Mecanismo de Atenção - Motivação

- Modelos anteriores usavam RNNs ou CNNs (ex: LSTM);
- Difíceis de paralelizar → lentos para treinar;
- Objetivo: melhorar eficiência e desempenho, eliminando recorrência.

Mecanismo de Atenção - Contribuição

- Proposta de uma nova arquitetura: Transformer;
- Baseado 100% em atenção → sem RNNs/CNNs;
- Mais rápido, paralelizável e com melhor desempenho.

Mecanismo de Atenção - Arquitetura do Transformer

- Composto por:
 - Encoder (6 camadas): processa entrada.
 - Decoder (6 camadas): gera saída.
- Cada camada tem:
 - Multi-Head Attention
 - Feedforward
 - Normalização + Residual

Mecanismo de Atenção - Arquitetura do Transformer




Figura: Arquitetura do Transformer

Mecanismo de Atenção - Self Attention

- Cada palavra olha para todas as outras da sequência;
- Calcula relações contextuais;
- Fórmula: $Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$
- Onde:
 - Q - Query: Vetor que faz a "pergunta" (sobre uma palavra);
 - K - Key: Vetores que representam possíveis "chaves de busca" (as outras palavras);
 - V - Value: Vetores com os conteúdos que queremos combinar/pesquisar;
 - d_k - Dimensão das chaves: Usado para evitar que o produto escalar fique com valores grandes demais.

Mecanismo de Atenção - Self Attention: Exemplo

- Imagine que queiramos processar a palavra: "O cachorro correu para o parque.";
 - Para entender o significado de "correu", talvez você queira prestar mais atenção nas palavras "cachorro" e "parque", e menos em "o" ou "para".
- A fórmula da atenção calcula pesos para cada palavra da frase com base em sua relevância para a palavra "correu".

Mecanismo de Atenção - Self Attention: Exemplo

- Simplificando: Dado a seguinte frase com representação vetorial: ["O", "cachorro", "correu"] e que $d_k = 2$, vamos analisar a atenção da palavra "correu";
- $Q(\text{"correu"}) = \begin{pmatrix} 1 & 0 \end{pmatrix}$; $K(\text{"O"}) = \begin{pmatrix} 1 & 1 \end{pmatrix}$;
 $K(\text{"cachorro"}) = \begin{pmatrix} 0 & 1 \end{pmatrix}$; $K(\text{"correu"}) = \begin{pmatrix} 1 & 0 \end{pmatrix}$;
- $V = K$;

Mecanismo de Atenção - Self Attention: Exemplo

- $QK_1^T = (1 \ 0) * \begin{pmatrix} 1 \\ 1 \end{pmatrix}^T = (1)$
- $QK_2^T = (1 \ 0) * \begin{pmatrix} 0 \\ 1 \end{pmatrix}^T = (0)$
- $QK_3^T = (1 \ 0) * \begin{pmatrix} 1 \\ 0 \end{pmatrix}^T = (1)$
- $QK^T = (1 \ 0 \ 1)$
- $\frac{QK^T}{\sqrt{d_k}} = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{0}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \approx (0.707 \ 0 \ 0.707)$

Mecanismo de Atenção - Multi-Head Attention

- Várias "cabeças" de atenção simultâneas.
- Permite aprender diferentes aspectos contextuais.
- Resultado: concatenação das cabeças → mais expressivo.

Mecanismo de Atenção - Positional Encoding

- Como não há ordem sequencial (como em RNNs), adiciona-se codificações de posição.
- Usa senos e cossenos para representar posições.

Referências

-  NeurIPS (2017)
"Attention is all you need."
<https://arxiv.org/abs/1706.03762>
-  Pizarro, I., Ñanculef, R., and Valle, C. (2023)
"An Attention-Based Architecture for Hierarchical Classification With CNNs."
<https://ieeexplore.ieee.org/document/10089461>
-  Zhu, X. and Bain, M. (2017)
"B-CNN: Branch Convolutional Neural Network for Hierarchical Classification."
Available at: <https://arxiv.org/abs/1709.09890>