

Inteligência Computacional: Entrega Parcial

Guilherme Campos Silva Lemes Prestes - 13720460 ¹

Armando Augusto Marchini Vidal - 13673072 ¹

¹Escola de Artes, Ciências e Humanidades da Universidade de São Paulo

Abril 2025

Definição do Problema

- Até então tínhamos muita inscositência hierárquica quando se CNNs, como B-CNN;
 - A limitação da B-CNN vem da sub-rede dedicada a prever um único nível hierárquico;
- Abordagens anteriores usavam modelo top-down com características hierárquicas propagadas de maneira unidirecional;
- O padrão de conexão é estático e não se adapta durante o treinamento.

- Usa-se a arquitetura de uma B-CNN como base e propõem uma extensão;
- A extensão é justamente a adesão de é modulo de atenção;
- A BA-CNN não exige conhecimento prévio das relações entre os níveis, pois aprende essas relações diretamente a partir dos dados.

Métodos




Figura: Árvore hierárquica reconstruída pela BA-CNN com o MNIST-

Métodos




Figura: B-CNN





Figura: BA-CNN



Coarse 1 prediction

Low-level features
(edges, textures)



Coarse 2 prediction

Intermediate-level features
(shapes, parts of objects)



Fine prediction

High-level features
(forms, fine details)

Figura: Exemplificação coarse

Desenho dos Experimentos - Conjuntos de Dados

- CIFAR-10: 60K imagens divididas em 10 classes; Hierarquia já conhecida
 - Benchmark padrão para estrutura
 - Base para análise entre modelos
 - Base-C e Base-B
- CIFAR-100: 600K imagens divididas em 100 classes; Hierarquia já conhecida
 - Testa desempenho e estabilidade em maior complexidade
- Fashion MNIST: 70K de imagens divididas em 10 classes; Hierarquia já conhecida
 - Testa a generalização e versatilidade do modelo

Desenho dos Experimentos - Hiperparâmetros

- BT (Branch Training) Strategy
 - Demarca o primeiro nível e depois muda o foco para classes mais detalhadas
 - Testes com e sem para testar seu impacto (e do módulo de atenção)
 - Depende da estrutura
- Módulo de Atenção
 - Padronização de informação para definir pesos
- Número de Neurônios
 - Módulo de Atenção: número de neurônios sem muito impacto uma camada escondida e 64 neurônios
 - Ramos Principais: melhor com menos neurônios

Desenho dos Experimentos - Medidas de Avaliação

- Acurácia hierárquica;
- Consistência hierárquica;




Figura: Consistência hierárquica boa e ruim

- Acurácia por níveis;
- F1 Score (média harmônica de precisão e recall);
- 5-fold-cross-validation

Melhores hiperparâmetros

Dataset	Branch No. Neurons	Mechanism No. Neurons	BT-Strategy
CIFAR-10	32	2048	True
CIFAR-100	256	2048	False
Fashion MNIST	16	2048	True

Figura: Best hyperparameters after the exhaustive grid search for CIFAR-10, CIFAR-100 and Fashion MNIST.

Discussão dos Resultados - Conclusões do Artigo

- Neurônios nos ramos principais
 - Concentrar as informações dos ramos em poucos neurônios "obriga" uma generalização melhor
- BT Startegy
 - Melhora a acurácia hierárquica
 - No CIFAR-100 que causa uma queda na performance
 - Diferentes métodos em diferentes estruturas

Discussão dos Resultados - Resumos Finais (CIFAR-10)

	Coarse 1	Coarse 2	Fine	h_Accuracy	h_Consistency	F1	Parameters
Flat CNN Base B	0	0	0,831	0	0	0	7.85MM
B-CNN Base B	0,959	0,8698	0,8425	0,7889	0,9028	0,890433	12.38MM
BA-CNN Base B	0,9673	0,8773	0,8348	0,8121	0,9542	0,893133	8.72MM
H-CNN Base B	0,9598	0,8708	0,842	0,7917	0,9085	0,890867	29.16MM
Add-net Base B	0,9581	0,8646	0,8332	0,7942	0,9287	0,8853	8.57MM
Concat-net Base B	0,9566	0,8673	0,8364	0,7927	0,9227	0,886767	12.39MM

Figura: Resultados da Reprodução para Base-B

Model w/BT-Strategy	Accuracy by Level			Hierarchical Metrics			Param. (MM)
	Level 1	Level 2	Level 3	Accuracy	Consistency	F1	
Flat CNN [15]	-	-	0.8267 (2.64e-03)	-	-	-	7.86
B-CNN [15]	0.9589 (8.75e-04)	0.8687 (2.33e-03)	0.8409 (3.02e-03)	0.7871 (2.57e-03)	0.9006 (1.99e-03)	0.8895 (1.54e-03)	12.38
BA-CNN	0.9683 (1.19e-03)	0.8796 (2.21e-03)	0.8395 (2.64e-03)	0.8148 (3.43e-03)	0.9495 (1.84e-03)	0.8958 (1.81e-03)	8.72
H-CNN [17]	0.9585 (1.37e-03)	0.8702 (1.45e-03)	0.8390 (1.62e-03)	0.7876 (1.91e-03)	0.9030 (3.18e-03)	0.8892 (1.12e-03)	29.16
Add-net [16]	0.9577 (1.87e-03)	0.8658 (1.53e-03)	0.8342 (2.08e-03)	0.7946 (2.07e-03)	0.9309 (2.62e-03)	0.8859 (1.15e-03)	8.57
Concat-net [16]	0.9570 (1.49e-03)	0.8662 (1.70e-03)	0.8360 (2.52e-03)	0.7926 (2.49e-03)	0.9226 (1.73e-03)	0.8864 (1.19e-03)	12.39

Figura: Resultados do Artigo para Base-B

Discussão dos Resultados - Resumos Finais (CIFAR-10)

	Coarse 1	Coarse 2	Fine	h_Accuracy	Consistency	F1	Parameters
Flat CNN Base C	0	0	0,88319999	0	0	0	39.95MM
B-CNN Base C	0,960699975	0,904999971	0,890900016	0,8281	0,8996	0,918866667	49.67MM
BA-CNN Base C	0,983299971	0,923399985	0,888700008	0,8814	0,9847	0,9318	15.81MM
H-CNN Base C	0,958700001	0,904900014	0,883300006	0,8263	0,9053	0,915633333	108.39MM
Add-net Base B	0,959599972	0,898699999	0,884199977	0,8334	0,9184	0,914166667	18.6MM
Concat-net Base B	0,957000017	0,897800028	0,881200016	0,8307	0,9229	0,912	49.69MM

Figura: Resultados da Reprodução para Base-C

Model w/BT-Strategy	Accuracy by Level			Hierarchical Metrics			Param. (MM)
	Level 1	Level 2	Level 3	Accuracy	Consistency	F1	
Flat CNN [46]	-	-	0.8823 (8.53e-04)	-	-	-	39.98
B-CNN [15]	0.9592 (1.34e-03)	0.9049 (1.51e-03)	0.8862 (2.06e-03)	0.8255 (1.52e-03)	0.8997 (1.48e-03)	0.9168 (8.70e-04)	49.67
BA-CNN	0.9823 (6.70e-04)	0.9191 (2.88e-03)	0.8837 (2.48e-03)	0.8751 (3.33e-03)	0.9803 (2.31e-03)	0.9284 (1.77e-03)	18.76
BA-CNN*	0.9836 (6.93e-04)	0.9230 (1.16e-03)	0.8880 (1.65e-03)	0.8829 (1.52e-03)	0.9877 (1.59e-03)	0.9315 (9.43e-04)	15.81
H-CNN [17]	0.9604 (1.46e-03)	0.9019 (1.47e-03)	0.8809 (1.17e-03)	0.8249 (1.77e-03)	0.9070 (2.80e-03)	0.9144 (7.57e-04)	108.39
Add-net [16]	0.9589 (1.08e-03)	0.8994 (1.63e-03)	0.8831 (1.46e-03)	0.8332 (1.23e-03)	0.9212 (1.53e-03)	0.9138 (7.84e-04)	18.60
Concat-net [16]	0.9578 (1.39e-03)	0.8994 (1.43e-03)	0.8810 (1.69e-03)	0.8312 (2.26e-03)	0.9212 (2.85e-03)	0.9127 (8.38e-04)	49.69

Figura: Resultados da Reprodução para Base-C

Discussão dos Resultados - Resumos Finais (CIFAR-100)

	Coarse 1	Coarse 2	Fine	h_Accuracy	h_Consistency	F1	Parameters
Flat CNN Base C	0.000000	0.000000	0.622300	0.000000	0.000000	0.000000	40.32MM
B-CNN Base C	0.744600	0.730800	0.624100	0.465100	0.603900	0.699833	50.06MM
BA-CNN Base C	0.840700	0.743700	0.614100	0.589600	0.896400	0.732833	23.42MM
H-CNN Base C	0.736100	0.719600	0.642700	0.473900	0.623500	0.699467	108.78MM
Add-net Base C	0.741000	0.702800	0.617400	0.474800	0.649800	0.687067	18.63MM
Concat-net Base C	0.740200	0.713800	0.619300	0.470900	0.627200	0.691100	50.22MM

Figura: Resultados da Reprodução

	Accuracy by Level			Hierarchical Metrics			Param. (MM)
	Level 1	Level 2	Level 3	Accuracy	Consistency	F1	
B-CNN [15]	0.7413 (2.62e-03)	0.7320 (2.28e-03)	0.6194 (2.85e-03)	0.4638 (2.76e-03)	0.6050 (3.91e-03)	0.6976 (2.00e-03)	50.06
BA-CNN	0.8415 (4.00e-03)	0.7427 (3.63e-03)	0.6080 (3.68e-03)	0.5854 (3.94e-03)	0.9028 (2.44e-03)	0.7307 (3.43e-03)	18.81
BA-CNN*	0.8409 (1.49e-03)	0.7447 (2.66e-03)	0.6124 (3.63e-03)	0.5887 (3.26e-03)	0.9025 (4.10e-03)	0.7327 (2.21e-03)	23.42
H-CNN [17]	0.7409 (1.99e-03)	0.7175 (2.69e-03)	0.6432 (2.67e-03)	0.4773 (2.18e-03)	0.6245 (3.31e-03)	0.7005 (6.20e-04)	108.78
Add-net [16]	0.7430 (2.93e-03)	0.7096 (3.96e-03)	0.6208 (2.64e-03)	0.4771 (3.09e-03)	0.6510 (3.45e-03)	0.6911 (1.12e-03)	18.63
Concat-net [16]	0.7391 (2.69e-03)	0.7157 (2.07e-03)	0.6213 (1.77e-03)	0.4723 (3.11e-03)	0.6272 (4.92e-03)	0.6920 (1.21e-03)	50.22

Discussão dos Resultados - Resumos Finais (MNIST)

	Coarse 1	Coarse 2	Fine	h_Accuracy	h_Consistency	F1	Parameters
Flat CNN Base C	0.000000	0.000000	0.622300	0.000000	0.000000	0.000000	40.32MM
B-CNN Base C	0.744600	0.730800	0.624100	0.465100	0.603900	0.699833	50.06MM
BA-CNN Base C	0.840700	0.743700	0.614100	0.589800	0.896400	0.732833	23.42MM
H-CNN Base C	0.736100	0.719600	0.642700	0.473900	0.623500	0.699467	108.78MM
Add-net Base C	0.741000	0.702800	0.617400	0.474800	0.649800	0.687067	18.63MM
Concat-net Base C	0.740200	0.713800	0.619300	0.470900	0.627200	0.691100	50.22MM

Figura: Resultados da Reprodução

Model w/BT-Strategy	Accuracy by Level			Hierarchical Metrics			Param. (MM)
	Level 1	Level 2	Level 3	Accuracy	Consistency	F1	
Flat CNN [15]	-	-	0.9299 (1.50e-03)	-	-	-	33.69
B-CNN [15]	0.9978 (3.25e-04)	0.9645 (1.25e-03)	0.9309 (1.17e-03)	0.9206 (1.36e-03)	0.9807 (1.03e-03)	0.9644 (6.39e-04)	40.56
BA-CNN	0.9977 (2.97e-04)	0.9662 (1.30e-03)	0.9312 (2.25e-03)	0.9262 (2.22e-03)	0.9903 (1.00e-03)	0.9650 (1.05e-03)	17.41
BA-CNN*	0.9978 (3.63e-04)	0.9663 (1.72e-03)	0.9313 (2.16e-03)	0.9280 (2.21e-03)	0.9932 (7.91e-04)	0.9652 (1.25e-03)	15.20
H-CNN [17]	0.9981 (2.79e-04)	0.9657 (1.06e-03)	0.9339 (1.52e-03)	0.9232 (1.49e-03)	0.9794 (1.25e-03)	0.9659 (5.85e-04)	82.11
Add-net [16]	0.9980 (2.61e-04)	0.9645 (1.05e-03)	0.9318 (1.42e-03)	0.9218 (1.78e-03)	0.9814 (1.26e-03)	0.9648 (7.14e-04)	17.25
Concat-net [16]	0.9979 (2.05e-04)	0.9638 (1.14e-03)	0.9314 (1.43e-03)	0.9209 (1.68e-03)	0.9809 (1.34e-03)	0.9644 (6.91e-04)	40.58

Figura: Resultados do Artigo

Apresentação Final

- Análise de novos dados
 - Olhos com e sem glaucoma
 - Diferentes tipos de glaucoma
- Teste de replicabilidade do resultado
 - Comparação de técnicas nos novos dados

Cronograma

- 05/05 à 19/05: Aplicação da técnica BA-CNN no novo conjunto
- 19/05 à 02/06: Estudo de quais técnicas usar para comparação; Comparação da BA-CNN com outras técnicas na nova base
- 02/06 à 18/06: Análise de resultados; Preparação da apresentação

Referências

-  IEEE Access Vol 11 (2023)
An Attention-Based Architecture for Hierarchical Classification With CNNs
10.1109/ACCESS.2023.3263472
-  Huang, X., Kong, X., Shen, Z. et al. (2023)
GRAPE: A multi-modal glaucoma dataset of follow-up visual field and fundus images for glaucoma management
Sci Data 10, 520 (2023).
-  ACRIMA (2019)
CNNs for Automatic Glaucoma Assessment using Fundus Images: An Extensive Validation
Figshare (2019).